

RAG 学习测试资料

用于 PDF 解析、文本切分、向量检索与问答实验

说明：这份资料包含可检索的事实信息。后续可以使用它测试 `chunk_size`、`chunk_overlap`、`top-k` 以及引用来源。文档中的名称和数据仅用于学习练习。

一、什么是 RAG

RAG 的英文全称是 Retrieval-Augmented Generation，中文通常翻译为检索增强生成。它将信息检索与大语言模型结合起来：系统先找到与问题相关的资料，再把资料交给大语言模型组织答案。

在一个典型流程中，文档会先被解析为文本，然后切分成多个较小的片段。每个片段经过 Embedding 模型处理后会变成向量，并写入向量数据库。用户提问时，问题也会被转换成向量，系统再检索语义相近的片段。

RAG 可以降低幻觉，但不能完全消除幻觉。模型仍然可能忽略资料、误解资料或者给出过度推断。因此，实际项目通常需要返回引用来源，并准备评测问题持续验证效果。

二、文本切分与重叠窗口

长文档通常不能直接全部发送给大语言模型。一方面，上下文窗口有限；另一方面，无关内容过多会增加成本，也可能干扰模型回答。因此，系统需要将长文档切分为若干 Chunk。

假设 `chunk_size` 设置为 500，`chunk_overlap` 设置为 100。第一个片段覆盖第 0 到第 500 个字符，第二个片段从第 400 个字符开始。两个片段之间保留约 100 个字符的重复内容。

重叠窗口的作用是减少边界信息丢失。如果一个关键定义刚好跨越两个片段，没有重叠时，任意一个片段都可能不完整。但是重叠比例过高也会造成冗余，增加向量存储量和检索噪声。

三、向量检索与 Top-K

Embedding 可以把文本转换成向量。语义较接近的文本，其向量通常也比较接近。向量数据库负责保存这些向量，并在用户提问时执行相似度检索。

`top-k` 表示检索阶段最多取回多少个候选片段。`top-k`

太小可能遗漏重要资料，导致回答缺少关键信息；`top-k` 太大则可能带入无关片段，增加 token 消耗，并干扰生成结果。

在学习项目中，可以先将 `top-k` 设置为 3 或

5，再结合测试问题观察效果。如果检索结果较多，还可以加入 Rerank 模型，对候选片段重新排序。

四、示例公司：星河科技

星河科技是一家虚构的软件公司。公司在 2024

年启动内部知识库项目，目标是帮助员工快速查询制度和项目资料。知识库平台由 Java SpringBoot 业务服务与 Python FastAPI 智能服务组成。

SpringBoot 服务负责用户登录、权限控制、知识库管理、聊天记录和文档状态。FastAPI 服务负责 PDF 解析、文本切分、Embedding、向量检索以及调用大语言模型。两个服务之间使用 HTTP 接口通信。

星河科技规定：普通员工只能访问所属部门的知识库；管理员可以创建知识库并上传文档。文档上传后进入异步解析队列。系统完成解析、切分和向量化后，文档状态才会从“处理中”变更为“可用”。

五、项目中的数据库分工

MySQL

用于存储结构化业务数据，例如用户、角色、知识库名称、文件名称、文档状态和聊天记录。Redis 可以用于缓存热点数据、保存短期会话信息以及实现简单限流。

向量数据库用于保存文本片段及其向量表示。它擅长回答“哪些片段在语义上最接近这个问题”。向量数据库不能完全替代

MySQL，因为用户、权限和文档状态等业务关系更适合存储在关系型数据库中。

六、测试问题

完成向量检索后，可以尝试回答以下问题：RAG 的英文全称是什么？chunk_overlap 有什么作用？top-k 太大有什么缺点？星河科技的平台由哪两个服务组成？普通员工可以访问哪些知识库？文档状态什么时候会变成“可用”？MySQL 与向量数据库的职责有什么不同？

建议：先使用 /documents/preview 接口上传本文档，观察 page_count、text_length、chunk_count 以及 preview_chunks。随后再进入 Embedding 和向量检索阶段。